



École Polytechnique de Lomé

Master international IA & Big Data

Rapport : Modèle de Traduction Multilingue (Français, Anglais, Ewe) avec Reconnaissance Vocale

Réalisé par : AREGBA-TISSOU Tchokoute Ulrich
TAGBA Awéréou
GLOKPOR Jean-Marie Emmanuel
NADJIRE Yendoukoa
KADANSAO Koboyo Lucien

Encadré par : Dr GBEDEVI

Année : 2025 – 2026

Table des matières

1	Introduction	3
1.1	Contexte et Justification du Projet	3
1.2	Objectif Général	3
1.3	Objectifs Spécifiques et Démarche	3
1.4	Structure du Rapport	3
1.4.1	Stratégies d'Entraînement et Approches de Fine-Tuning	4
1.4.2	Évaluation et Comparaison des Modèles	4
1.5	Qu'est-ce que le Fine-Tuning ?	4
1.5.1	Pourquoi le Fine-Tuning est-il indispensable pour l'Éwé ?	4
1.6	Défis et Problématiques du Fine-Tuning	5
1.6.1	Le Catastrophic Forgetting (Oubli Catastrophique)	5
1.6.2	L'Overfitting (Surapprentissage) sur les Faibles Ressources	5
1.6.3	Le Coût Computationnel et la Limitation Matérielle	5
1.7	La Dégradation de la Robustesse et l'Amplification des Biais	5
1.7.1	Description des Métriques d'Évaluation Automatique	5
2	Collecte et Prétraitement des Données	7
2.1	Sources de Données et Constitution du Corpus	7
2.2	Processus de Prétraitement des Données	8
2.3	Corpus d'Évaluation et Références (Baselines)	8
2.3.1	Paire Éwé – Anglais	8
2.3.2	Paire Éwé – Français	8
2.3.3	Paire Français – Anglais	9
2.4	Architecture du modèle NLLB-600M et stratégies d'ajustement	9
2.4.1	Le modèle NLLB-600M	9
2.4.2	Stratégies de fine-tuning	9
2.4.3	Comparatif des méthodes	10
2.5	Ajustement Complet (Full Fine-Tuning)	10
2.5.1	Éwé → Anglais — FP32 avec optimiseur 8-bit	10
2.5.2	Éwé → Français — Quantification INT8 avec optimiseur 8-bit	11
2.5.3	Éwé → Français — Précision mixte FP16 avec optimiseur 8-bit	11
2.6	Ajustement Partiel par Adaptateurs LoRA (PEFT)	11
2.6.1	Éwé → Anglais (Kaggle T4×2)	12
2.6.2	Éwé → Français (Kaggle T4×2)	12
2.6.3	Français → Anglais (Google Colab)	13
2.6.4	Adaptateur LoRA Multilingue (Éwé → Anglais et Éwé → Français)	13
2.7	Synthèse Comparative des Entraînements	14
2.8	Reconnaissance Vocale Automatique (ASR) en Éwé	14
2.8.1	Spécificités Linguistiques et Défis Acoustiques de l'Éwé	14
2.8.2	Architecture d'un Système ASR Appliqué à l'Éwé	15
2.8.3	Le Problème de la Rareté des Ressources (<i>Low-Resource Language</i>)	15
2.9	Évaluation des performances du système ASR	15
2.9.1	Présentation des métriques d'évaluation	15
2.9.2	Résultats de la spécialisation du modèle	15

2.9.3	Analyse des performances	16
2.9.4	Enrichissement ASR avec WaxalNLP (v2 — en cours)	16
3	Bilan, Limites et Perspectives	17
3.1	Récapitulatif des Modèles Produits	17
3.2	Bilan Global	17
3.3	Limites Actuelles	17
3.4	Perspectives d'Amélioration	18
4	Ressources Numériques et Liens Utiles	19

1. Introduction

1.1 Contexte et Justification du Projet

À l'ère de la mondialisation et de la numérisation croissante, la communication interculturelle est devenue un pilier fondamental du développement socio-économique. Si le français et l'anglais s'imposent comme des langues de communication internationales et administratives prédominantes, les langues locales demeurent le canal privilégié d'expression et d'intégration des populations au quotidien. Au Togo, l'Ewe occupe une place centrale dans les échanges culturels et commerciaux. Cependant, la barrière linguistique entre ces langues internationales et les réalités locales freine l'accessibilité à l'information et l'inclusion numérique d'une grande partie de la population.

Bien que les technologies de traitement automatique du langage naturel (NLP - *Natural Language Processing*) aient connu des avancées fulgurantes ces dernières années, force est de constater que les langues africaines, et plus particulièrement l'Ewe, restent largement sous-représentées. Qualifiée de langue à faibles ressources (*low-resource language*), l'Ewe souffre d'un manque crucial de corpus textuels et audio structurés et standardisés, ce qui limite l'efficacité des outils de traduction automatique grand public actuels.

1.2 Objectif Général

Le présent projet s'inscrit dans cette perspective. Son objectif central est **avant tout de réunir un corpus multilingue suffisamment riche et diversifié** en français, anglais et éwé : sans données parallèles de qualité, aucun entraînement fiable n'est possible pour une langue aussi peu dotée numériquement que l'éwé. Sur la base de ce corpus, l'objectif suivant est de concevoir et de développer un système de traduction automatique et vocale. En s'appuyant sur des techniques avancées de *Machine Learning* et de NLP, ce système vise à briser les barrières linguistiques et à promouvoir la digitalisation des langues locales à travers une solution technologique accessible.

1.3 Objectifs Spécifiques et Démarche

Pour mener à bien cette ambition, le projet s'articule autour de plusieurs défis techniques et scientifiques majeurs, déclinés en objectifs spécifiques selon un ordre de priorité :

- **Constitution et enrichissement du corpus (priorité n° 1) :** Collecter, nettoyer et agréger des données textuelles et audio en français, anglais et éwé depuis des sources variées (OPUS, Masakhane, Kaggle, WaxalNLP, BibleTTS. . .) afin d'obtenir un volume et une diversité de domaines suffisants. Sans corpus adéquat, aucun modèle ne peut être entraîné de manière fiable.
- **Prétraitement des données :** Mettre en œuvre des pipelines de nettoyage, de tokenisation et d'alignement rigoureux pour garantir la qualité et la cohérence des corpus parallèles avant l'entraînement.
- **Modélisation de la traduction :** Entraîner et optimiser des modèles d'apprentissage profond (*Deep Learning*), notamment des architectures séquentielles (*Seq2Seq*) et des *Transformers*, pour assurer une traduction fluide entre les paires : Français ↔ Anglais, Français ↔ Ewe, et Anglais ↔ Ewe.
- **Reconnaissance vocale :** Intégrer un module de *Speech-to-Text* (STT) afin de permettre une interaction et une traduction orale, essentielle pour l'accessibilité de l'application.
- **Déploiement pratique :** Concevoir une interface utilisateur (Web ou Mobile) ergonomique et intuitive permettant de tester et de valider les performances du traducteur en conditions réelles.

1.4 Structure du Rapport

Le présent rapport est structuré de la manière suivante : après cette introduction, le premier chapitre sera consacré à l'état de l'art du NLP appliqué aux langues à faibles ressources et aux concepts théoriques de la traduction automatique. Le deuxième chapitre détaillera la phase de collecte, de nettoyage et de prétraitement des données textuelles et audio. Enfin, le troisième chapitre présentera l'architecture des modèles retenus, les phases d'entraînement, ainsi que l'évaluation des résultats obtenus à travers l'interface utilisateur.

1.4.1 Stratégies d'Entraînement et Approches de Fine-Tuning

Afin de maximiser les performances de nos modèles de traduction, en particulier pour les paires impliquant l'Ewe (langue à faibles ressources), plusieurs stratégies d'ajustement fin (*fine-tuning*) sont explorées, implémentées et comparées :

- **Full Fine-Tuning (Ajustement Complet - 32/16/8 bits)** : Cette approche consiste à réentraîner l'intégralité des paramètres du modèle pré-entraîné sur nos corpus parallèles. Pour surmonter les contraintes matérielles liées à la mémoire GPU, nous mettons en œuvre des techniques de quantification en **32 bits (FP32)**, en **16 bits (FP16/BF16)** et en **8 bits (INT8)**. Cela permettra de stabiliser l'apprentissage tout en réduisant l'empreinte mémoire sans dégradation majeure de la précision.
- **Fine-Tuning Partiel via LoRA (Low-Rank Adaptation)** : À l'inverse de l'ajustement complet, la méthode de *Parameter-Efficient Fine-Tuning* (PEFT), et plus précisément l'architecture **LoRA**, sera exploitée. En gelant les poids d'origine du modèle et en y injectant des matrices de bas rang dans les couches d'attention, LoRA permettra d'adapter efficacement le modèle à la spécificité de la langue Ewe. Cette technique offre l'avantage d'accélérer considérablement le temps d'entraînement et de réduire drastiquement le nombre de paramètres modifiables.

1.4.2 Évaluation et Comparaison des Modèles

L'un des verrous scientifiques de ce projet a résidé dans la sélection de l'architecture la plus robuste pour la traduction multilingue. Une phase rigoureuse d'**analyse comparative** a ainsi été menée entre les différents modèles entraînés, confrontant notamment les modèles de base *Seq2Seq* aux architectures *Transformers*, ainsi que les approches entièrement ajustées (*Full Fine-Tuning*) aux variantes optimisées avec LoRA.

Cette confrontation s'est appuyée sur des métriques d'évaluation standardisées en traitement automatique du langage naturel (NLP), telles que le score **BLEU** (*Bilingual Evaluation Understudy*) et le score **CHRF**. L'objectif a été d'identifier le meilleur compromis entre la fluidité de la traduction, la précision sémantique et la légèreté computationnelle du modèle final avant son intégration dans l'interface utilisateur.

1.5 Qu'est-ce que le Fine-Tuning ?

Le **fine-tuning** (ou ajustement fin) est une technique d'apprentissage par transfert (*Transfer Learning*) qui consiste à prendre un modèle de *Machine Learning* ou de *Deep Learning* déjà pré-entraîné sur une tâche source massive, puis à l'adapter sur un nouvel ensemble de données plus restreint et spécifique à une tâche cible.

Dans le contexte du traitement automatique des langues (NLP) et de notre projet de traducteur, le processus se déroule en deux grandes étapes :

1. **L'Ajustement Fin Complet (*Full Fine-Tuning*)** : Cette approche consiste à débloquent l'intégralité des couches de l'architecture du modèle afin de mettre à jour la totalité de ses poids synaptiques lors de l'apprentissage. Bien qu'elle permette une adaptation en profondeur aux spécificités lexicales et morphosyntaxiques complexes de la langue Ewe, elle s'accompagne d'un coût computationnel extrêmement élevé (exigeant une VRAM massive) et d'un risque d'oubli catastrophique (*catastrophic forgetting*) des connaissances générales acquises lors du pré-entraînement.
2. **L'Ajustement Fin Économe via LoRA (*Low-Rank Adaptation*)** : Cette méthode fige les poids originaux du modèle pré-entraîné et injecte des matrices de décomposition à bas rang dans les couches d'attention du *Transformer*. Seuls ces adaptateurs légers sont mis à jour, ce qui réduit drastiquement le nombre de paramètres entraînés, optimise l'empreinte mémoire et préserve la robustesse initiale du modèle tout en l'alignant efficacement sur nos paires de langues (Français, Anglais, Ewe).

1.5.1 Pourquoi le Fine-Tuning est-il indispensable pour l'Ewe ?

L'utilisation du fine-tuning est cruciale pour ce projet pour trois raisons majeures :

- **Gestion des faibles ressources** : L'Ewe dispose de très peu de données textuelles sur le web. Entraîner un modèle de traduction de zéro (*from scratch*) avec si peu de données mènerait à un échec (surapprentissage ou *overfitting*). Le fine-tuning permet de transférer l'intelligence d'un modèle généraliste vers l'Ewe, même avec un volume de données réduit.
- **Gain de temps et de ressources** : Réentraîner un modèle complet nécessite des semaines de calcul sur des clusters de GPU. Le fine-tuning permet d'obtenir des modèles hautement performants en seulement

quelques heures ou jours d'entraînement.

- **Spécialisation** : Il permet d'aligner le comportement du modèle sur les nuances culturelles et linguistiques spécifiques du Togo (notamment pour l'alignement des expressions idiomatiques entre le français, l'anglais et l'ewe).

1.6 Défis et Problématiques du Fine-Tuning

Bien que le *fine-tuning* soit une méthode puissante, son application à des modèles de grande taille et à des langues à faibles ressources comme l'Ewe soulève plusieurs défis techniques et théoriques majeurs.

1.6.1 Le Catastrophic Forgetting (Oubli Catastrophique)

L'**oubli catastrophique** est l'un des problèmes majeurs du *full fine-tuning*. Lorsque l'intégralité des poids d'un modèle pré-entraîné est ajustée pour une nouvelle tâche (par exemple, la traduction vers l'Ewe), le modèle a tendance à écraser ou "effacer" les connaissances générales qu'il avait acquises lors de sa phase de pré-entraînement.

- *Conséquence* : Le modèle peut devenir excellent pour traduire le français vers l'Ewe, mais perdre une partie de ses capacités initiales de compréhension fine de la syntaxe complexe ou de traduction sur d'autres paires de langues (comme le Français ↔ Anglais).

1.6.2 L'Overfitting (Surapprentissage) sur les Faibles Ressources

L'Ewe étant une langue à faibles ressources, le volume de données collecté (via Masakhane et OPUS) reste modeste par rapport aux standards du *Deep Learning*.

- *Le risque* : Si un grand modèle avec des millions de paramètres libres est entraîné trop longtemps sur un petit corpus, il va mémoriser les phrases du jeu d'entraînement par cœur plutôt que d'apprendre les règles de grammaire sous-jacentes.
- *Conséquence* : Le score BLEU sera excellent sur les données de test proches, mais le traducteur échouera complètement face à de nouvelles phrases en conditions réelles.

1.6.3 Le Coût Computationnel et la Limitation Matérielle

Le *Full Fine-Tuning* nécessite de stocker en mémoire GPU non seulement les poids du modèle, mais aussi les gradients et les états de l'optimiseur (comme AdamW) pour chaque paramètre. Pour un modèle de taille moyenne, cela dépasse rapidement la mémoire vidéo (VRAM) des cartes graphiques standard.

C'est précisément ce problème qui a justifié, dans le cadre de ce projet, l'utilisation de la plateforme infonuagique **Google Colab** combinée à des techniques d'optimisation :

- **Contraintes matérielles de Google Colab** : L'accès aux GPU de type **NVIDIA T4** (disposant d'environ 15 Go de VRAM) s'est avéré insuffisant pour supporter l'architecture complète sans provoquer d'erreurs de saturation mémoire (*Out Of Memory*). De plus, la limite de temps des sessions a imposé une gestion stricte des sauvegardes (*checkpoints*).
- **Stratégies de contournement** : Pour surmonter ces barrières, nous avons exploité la **quantification (8/16 bits)** et des méthodes de *Parameter-Efficient Fine-Tuning* (PEFT) comme **LoRA**. Cela a permis de figer les poids d'origine et de ne mettre à jour qu'un nombre drastiquement réduit de paramètres via des matrices à bas rang, optimisant ainsi l'empreinte mémoire tout en préservant la stabilité du modèle.

1.7 La Dégradation de la Robustesse et l'Amplification des Biais

Si le corpus de spécification (les données de scraping ou les textes religieux d'OPUS) contient des biais linguistiques ou un vocabulaire trop ciblé, le modèle va les amplifier :

- **Biais de domaine** : Un modèle ajusté majoritairement sur des textes bibliques issus d'OPUS adoptera un ton solennel ou un vocabulaire archaïque, même lorsqu'on lui demandera de traduire des phrases de la vie courante.
- **Hallucinations** : En situation de surapprentissage ou face à un mot inconnu (OOV - *Out-Of-Vocabulary*), le modèle régressera en générant des phrases fluides en apparence mais sémantiquement fausses ou inventées.

1.7.1 Description des Métriques d'Évaluation Automatique

La validation quantitative des traductions générées a reposé sur l'utilisation de métriques standardisées en traitement automatique du langage naturel (NLP). Ces indicateurs permettent de mesurer de manière objective

la proximité linguistique et sémantique entre les prédictions du modèle et les traductions humaines de référence. Le tableau 1.1 détaille la signification, le rôle et l'interprétation de chaque score exploité lors des phases de test :

Métrique	Description, Représentation et Interprétation
Score BLEU	Évalue la précision du modèle en calculant le taux de n-grammes (mots) communs entre la traduction prédite et la référence. Intègre une pénalité de brièveté. Interprétation : Plus le score est élevé, plus la traduction est fidèle au style humain.
ROUGE-1 (F1)	Mesure le taux de recouvrement des unigrammes (mots uniques) entre la prédiction et la référence. Interprétation : Indique la bonne traduction du vocabulaire essentiel et des mots-clés.
ROUGE-2 (F1)	Calcule le taux de recouvrement des bigrammes (paires de mots). Plus strict sur l'ordre local des mots. Interprétation : Témoigne de la fluidité locale et du respect de la syntaxe.
ROUGE-L (F1)	Évalue la structure globale via la plus longue sous-suite commune (<i>Longest Common Subsequence</i>). Interprétation : Confirme la cohérence globale et la restitution du sens de la phrase.
chrF++	Basé sur les n-grammes de caractères (et non de mots), il calcule la moyenne harmonique entre la précision et le rappel au niveau des caractères, en incluant les unigrammes de mots. Interprétation : Très robuste pour les langues morphologiquement riches comme l'Éwé, il mesure la précision morphologique même en cas de faible vocabulaire.

TABLE 1.1 – Synthèse, rôle et interprétation des métriques d'évaluation utilisées dans le projet.

2. Collecte et Prétraitement des Données

2.1 Sources de Données et Constitution du Corpus

La constitution d'un corpus de qualité est **l'étape fondatrice du projet** : sans données parallèles suffisamment volumineuses et diversifiées, aucun modèle de traduction ou de reconnaissance vocale ne peut apprendre les spécificités de la langue éwé. La collecte de données a donc été menée en amont de tout entraînement, en agrégeant plusieurs sources publiques aux domaines variés (textes religieux, journalistiques, littéraires, droits de l'homme, audio studio). Pour ce projet impliquant le français, l'anglais et l'ewe, les données proviennent de différentes plateformes reconnues dans le domaine de la recherche en NLP :

TABLE 2.1 – Synthèse des sources de données par paire de langues

Paire de langues	Source de données	Description / URL
Français ↔ Ewe	Masakhane (Lafand-MT)	Corpus de textes journalistiques et documentaires de l'organisation Masakhane, disponible sur GitHub (Lafand-MT).
Anglais ↔ Ewe	OPUS Open Source Corpus	Base de données multilingue libre, regroupant des textes religieux (la Bible), des documents législatifs et des traductions communautaires sur OPUS.
Anglais ↔ Ewe	Kaggle — tchaye59	Paires bilingues Éwé-Anglais (7,2 Mo, 3 colonnes), issues de textes littéraires, JW.org, DUDH et peterlin.pl. Licence libre pour la recherche. Lien Kaggle.
Anglais ↔ Ewe	Kaggle — kuroio	Fichier CSV Éwé-Anglais complémentaire (5,6 Mo, 2 colonnes), licence MIT. À vérifier pour chevauchement avec la source tchaye59. Lien Kaggle.
Français ↔ Anglais	Kaggle	Datasets massifs et diversifiés (littérature, sous-titres, actualités) disponibles sur la plateforme de science de données Kaggle.
Éwé (ASR)	WaxalNLP (Google)	Corpus audio multilingue annoté, contenant ≈15 000 clips éwé (config ewe_asr) sur Hugging Face.
Éwé (ASR / TTS)	BibleTTS — OpenSLR 129	Corpus audio haute qualité, 48 kHz mono FLAC, 86,8 heures alignées pour l'éwé (24 957 énoncés, locuteur unique, studio). Licence CC BY-SA 4.0. openslr.org/129.

Les données proviennent de différentes sources publiques (cliquez sur ce [lien vers les données](#) pour voir les liens en fin de document).

Environnement d'entraînement. Les expériences d'ajustement fin ont été conduites sur deux plateformes complémentaires : **Google Colab** (GPU NVIDIA T4, sessions de 3h30–4h par jour) pour les phases de *Full Fine-Tuning*, et **Kaggle** (GPU T4 ×2, quota 30 h/semaine) pour les adaptateurs LoRA et la reconnaissance vocale (ASR). Le corpus d'entraînement unifié pour la traduction a été constitué au format **JSONL** dans le répertoire `nllb_translation/`, combinant OPUS (Bible), Masakhane (Lafand-MT) et les paires Français-Anglais Kaggle (≈222 000 lignes d'entraînement au total).

Les sources additionnelles identifiées (tchaye59, kuroio sur Kaggle, BibleTTS sur OpenSLR) n'ont pas encore été intégrées dans les corpus d'entraînement actuels. Elles constituent des pistes concrètes d'enrichissement pour les phases d'entraînement ultérieures.

2.2 Processus de Prétraitement des Données

Une fois la collecte effectuée, un pipeline rigoureux de prétraitement est indispensable, en particulier pour intégrer l'Ewe qui présente des spécificités de caractères propres (comme les lettres de l'alphabet africain de référence : $\alpha, \beta, \varepsilon, j, \eta, \theta, \varnothing, v, \chi, \omega$). Le pipeline de traitement se divise en plusieurs étapes clés :

1. Extraction et Nettoyage :

- Extraction des données à partir des différents formats sources (fichiers TSV, formats bruts OPUS et archives Kaggle).
- Élimination des balises HTML résiduelles, des métadonnées inutiles (comme les fichiers système de type .DS_Store), des doublons et des lignes vides.
- Normalisation du texte : gestion de la casse (mise en minuscules contrôlée), harmonisation de la ponctuation et suppression des caractères spéciaux non standard.

2. Alignement des Corpus Parallèles :

- Vérification de la correspondance stricte ligne par ligne pour chaque phrase de la langue source vers la langue cible.
- Filtrage basé sur la longueur des phrases pour éliminer les segments disproportionnés (par exemple, une phrase très longue traduite par un seul mot), ce qui pourrait fausser l'apprentissage du *Transformer*.

3. Tokenisation et Segmentation en Sous-mots :

- Application d'un algorithme de tokenisation adapté aux langues à faibles ressources (tel que *Byte-Pair Encoding* (BPE) ou *SentencePiece*). Cette étape permet de découper les mots en sous-unités afin de limiter la taille du vocabulaire et de résoudre le problème des mots hors-vocabulaire (*Out-Of-Vocabulary* - OOV), fréquent en Ewe.

2.3 Corpus d'Évaluation et Références (Baselines)

Avant toute phase d'entraînement, les corpus parallèles ont été découpés en trois sous-ensembles (train/validation/test) et les performances initiales du modèle **NLLB-200-distilled-600M** brut ont été mesurées sur chaque paire de langues. Ces scores de référence (*baseline*) permettent de quantifier précisément l'apport de chaque méthode d'ajustement fin.

2.3.1 Paire Éwé – Anglais

Le corpus chargé depuis le Hub Hugging Face et nettoyé sur Kaggle (suppression des doublons, copies source = cible, caractères éwé dans les cibles anglaises) se répartit comme suit : **34 775 paires d'entraînement / 4 351 de validation / 4 336 de test**.

Jeu de données	Proportion	Volume (Paires)
Entraînement (<i>Train</i>)	80 %	34 775
Validation (<i>Val</i>)	20 %	4 351
Total Apprentissage	100 %	39 126
Test (<i>Test</i>)	—	4 336

TABLE 2.2 – Répartition du corpus Éwé-Anglais (après nettoyage, Kaggle).

Baseline NLLB brut (test complet, $n = 4\,336$) : BLEU = 13,83 chrF++ = 33,09

2.3.2 Paire Éwé – Français

Le corpus Éwé-Français, plus restreint, est constitué des paires ewe_Latn–fra_Latn du jeu de données unifié. Après nettoyage, on dispose de **2 362 paires de test**.

Jeu de données	Proportion	Volume (Paires)
Entraînement (<i>Train</i>)	80 %	18 931
Validation (<i>Val</i>)	20 %	2 366
Total Apprentissage	100 %	21 297
Test (<i>Test</i>)	—	2 367

TABLE 2.3 – Répartition du corpus Éwé-Français (avant nettoyage, fichiers locaux).

Baseline NLLB brut (test complet, $n = 6\,760$) : BLEU = 3,15 chrF++ = 18,72

2.3.3 Paire Français – Anglais

Le corpus Français-Anglais, de loin le plus volumineux, provient de sources Kaggle (littérature, sous-titres, actualités). Un sous-ensemble de **2 000 lignes** a été isolé pour le jeu de test.

Jeu de données	Proportion	Volume (Paires)
Entraînement (<i>Train</i>)	80 %	138 897
Validation (<i>Val</i>)	20 %	34 724
Total Apprentissage	100 %	173 621
Test (<i>Test</i>)	—	2 000

TABLE 2.4 – Répartition du corpus Français-Anglais.

Baseline NLLB brut : BLEU = 5,67 ROUGE-L = 53,27 %

2.4 Architecture du modèle NLLB-600M et stratégies d’ajustement

2.4.1 Le modèle NLLB-600M

Le modèle **NLLB** (*No Language Left Behind*), développé par Meta AI, repose sur une architecture *Transformer* (encodeur-décodeur) conçue pour la traduction automatique multilingue. La variante **600M** totalise environ **600 millions de paramètres**. Ce modèle a été pré-entraîné sur un corpus massif, lui conférant une excellente capacité à capturer les nuances syntaxiques entre des centaines de langues, incluant des langues à ressources limitées comme l’Éwé.

2.4.2 Stratégies de fine-tuning

Pour adapter ce socle linguistique à nos paires de langues, deux approches ont été explorées :

Full Fine-Tuning (Ajustement complet)

Le *Full Fine-Tuning* consiste à mettre à jour l’intégralité des 600 millions de paramètres du modèle.

- **Principe** : Chaque poids du réseau est réajusté lors de la rétropropagation, permettant une adaptation profonde aux spécificités linguistiques de l’Éwé.
- **Contrainte** : Cette méthode est exigeante en ressources de calcul (VRAM). Elle nécessite l’usage de techniques d’optimisation comme la quantification 8-bit ou la précision mixte (BF16) pour garantir la stabilité sur Google Colab.

Adaptation par LoRA (Low-Rank Adaptation)

LoRA est une méthode d’ajustement efficace en paramètres (*PEFT*) qui limite le nombre de poids à entraîner.

- **Principe** : Au lieu de modifier les 600 millions de paramètres du modèle, on "gèle" le modèle de base et on injecte des matrices de bas rang dans les couches du *Transformer*.
- **Complexité** : Cette méthode réduit drastiquement le nombre de paramètres mis à jour, passant de 600 millions lors d’un *Full Fine-Tuning* à environ **2 millions de paramètres** pour nos adaptateurs LoRA.
- **Avantages** : Le modèle résultant est extrêmement léger, facilitant le déploiement sur des systèmes aux ressources restreintes tout en conservant une qualité de traduction très compétitive.

2.4.3 Comparatif des méthodes

Caractéristique	Full Fine-Tuning	LoRA
Paramètres entraînés	600 millions	1 à 2 millions
Poids du fichier final	Plusieurs Go	Très léger
Complexité de calcul	Élevée	Faible
Usage recommandé	Précision maximale	Déploiement agile/mobile

TABLE 2.5 – Comparaison des stratégies d’ajustement du modèle NLLB.

2.5 Ajustement Complet (Full Fine-Tuning)

Le *Full Fine-Tuning* consiste à mettre à jour la **totalité des poids** du modèle NLLB pré-entraîné sur notre corpus. Toutes les expériences de cette section ont été menées sur **Google Colab** (GPU NVIDIA T4, 15 Go de VRAM), en combinant la quantification (INT8 ou FP16) et l’optimiseur 8-bit (`bitsandbytes`) pour tenir dans la mémoire disponible. Cette approche produit un modèle complet (838 Mo à 3,46 Go selon la précision) mais présente un risque d’*overfitting* sur les faibles ressources éwé.

2.5.1 Éwé → Anglais — FP32 avec optimiseur 8-bit

Paramètre	Valeur
Plateforme	Google Colab (NVIDIA T4, 15 Go VRAM)
Taille de lot (<i>Batch Size</i>)	2
Accumulation de gradients	2 (batch effectif = 4)
Taux d’apprentissage	2×10^{-5}
Nombre d’époques	3
Durée totale	≈ 14 h (4 sessions Colab)
Poids du modèle final	3,46 Go

TABLE 2.6 – Hyperparamètres — Full FT Éwé→Anglais (FP32).

Époque	Loss	BLEU (Validation)
1	0,1452	15,48
2	0,0384	19,12
3	0,0021	22,26

TABLE 2.7 – Évolution des métriques — Full FT Éwé→Anglais (FP32).

Le BLEU de validation progresse de 15,48 à **22,26** (+10,1 pts). Cependant, la loss quasi-nulle (0,0021) à l’époque 3 est un signal d’*overfitting* : le modèle mémorise le corpus au lieu de généraliser.

2.5.2 Éwé → Français — Quantification INT8 avec optimiseur 8-bit

Paramètre	Valeur
Plateforme	Google Colab (NVIDIA T4)
Quantification	INT8 (<code>load_in_8bit=True</code>)
Taille de lot	8
Accumulation de gradients	8 (batch effectif = 64)
Taux d'apprentissage	2×10^{-5}
Nombre d'époques	5
Durée totale	≈ 4 h
Poids du modèle final	838,3 Mo

TABLE 2.8 – Hyperparamètres — Full FT Éwé→Français (INT8).

Époque	Loss	BLEU	ROUGE-1 (%)	ROUGE-2 (%)	ROUGE-L (%)
1	—	3,29	31,88	9,95	27,42
2	5,09	3,51	32,06	10,15	27,62
3	2,99	3,57	32,00	10,21	27,64

TABLE 2.9 – Évolution des métriques — Full FT Éwé→Français (INT8).

Le BLEU passe modestement de 3,29 à **3,57**, dépassant légèrement la baseline (3,41). La quantification INT8 compresse le modèle à 838 Mo mais limite la précision des gradients.

2.5.3 Éwé → Français — Précision mixte FP16 avec optimiseur 8-bit

Paramètre	Valeur
Plateforme	Google Colab (NVIDIA T4)
Précision	FP16 (précision mixte, <i>bf16/fp16</i>)
Taille de lot	8
Accumulation de gradients	8 (batch effectif = 64)
Nombre d'époques	3
Poids du modèle final	1,15 Go

TABLE 2.10 – Hyperparamètres — Full FT Éwé→Français (FP16).

Époque	BLEU	ROUGE-L (%)
1	4,00	28,52
2	4,11	28,61
3	4,14	28,62

TABLE 2.11 – Évolution des métriques — Full FT Éwé→Français (FP16).

La précision FP16 améliore la convergence par rapport à l'INT8 : BLEU **4,14** contre 3,57, grâce à une meilleure intégrité des gradients. Toutefois, les deux approches Full FT restent nettement inférieures aux résultats LoRA (voir section suivante).

2.6 Ajustement Partiel par Adaptateurs LoRA (PEFT)

La technique **LoRA** (*Low-Rank Adaptation*) gèle tous les poids du modèle NLLB et injecte de petites matrices $A \in \mathbb{R}^{r \times d}$ et $B \in \mathbb{R}^{d \times r}$ dans les couches d'attention ($\Delta W = BA$, rang $r = 16$). Seules ces matrices

sont entraînées, ce qui représente $\approx 0,17\%$ des paramètres (2,36 M sur 1,4 G total). Hyperparamètres LoRA communs à toutes les expériences : $r = 16$, $\alpha = 32$, $dropout = 0,05$, modules ciblés : `q_proj` et `v_proj`, `use_rslora=True` (mise à l'échelle $\alpha/\sqrt{r}$, plus stable pour r élevé).

2.6.1 Éwé → Anglais (Kaggle T4×2)

Paramètre	Valeur
Plateforme	Kaggle (T4×2, 1 GPU actif)
Données	34 775 train / 4 351 val / 4 336 test
Taux d'apprentissage	3×10^{-4} (scheduler cosinus)
Taille de lot	4
Accumulation de gradients	4 (batch effectif = 16)
Warmup ratio	0,06
Nombre d'époques	3
Steps totaux	6 522
Loss finale d'entraînement	6,98
Durée totale	≈ 1 h 54
Taille de l'adaptateur	≈ 30 Mo

TABLE 2.12 – Hyperparamètres — LoRA Éwé→Anglais.

Phase	BLEU	chrF++ (%)
Baseline (NLLB brut, $n = 4\,336$)	13,83	33,09
Fine-tuning LoRA (test)	27,47	46,09
Gain	+13,64	+13,00

TABLE 2.13 – Résultats LoRA Éwé→Anglais (jeu de test, $n = 4\,336$).

2.6.2 Éwé → Français (Kaggle T4×2)

Paramètre	Valeur
Plateforme	Kaggle (T4×2, 1 GPU actif)
Données	18 931 train / 2 366 val / 2 362 test (après nettoyage)
Taux d'apprentissage	3×10^{-4} (scheduler cosinus)
Taille de lot	4
Accumulation de gradients	4 (batch effectif = 16)
Nombre d'époques	3
Steps totaux	3 543
Loss finale d'entraînement	10,34
Durée totale	≈ 1 h 00
Taille de l'adaptateur	≈ 30 Mo

TABLE 2.14 – Hyperparamètres — LoRA Éwé→Français.

Phase	BLEU	chrF++ (%)
Baseline (NLLB brut, $n = 6\,760$)	3,15	18,72
Fine-tuning LoRA (test)	6,94	25,42
Gain	+3,79	+6,70

TABLE 2.15 – Résultats LoRA Éwé→Français (jeu de test, $n = 2\,362$).

La progression du BLEU (+3,79) et du chrF++ (+6,70) confirme l’apport du fine-tuning. Le score absolu reste modeste, caractéristique des langues à faibles ressources sur un corpus restreint.

2.6.3 Français → Anglais (Google Colab)

Cet adaptateur couvre la direction **Français** → **Anglais** uniquement.

Paramètre	Valeur
Plateforme	Google Colab (NVIDIA T4)
Données	138 897 train / 34 724 val / 2 000 test
Taille de lot	8
Accumulation de gradients	4 (batch effectif = 32)
Nombre d’époques	3
Durée totale	≈ 4 h
Taille de l’adaptateur	14 Mo

TABLE 2.16 – Hyperparamètres — LoRA Français→Anglais.

Résultats à la clôture de l’époque 1 :

- Loss d’entraînement : 0,0084
- **Score BLEU (validation) : 61,17** (+55,5 pts par rapport à la baseline 5,67)

Ce saut exceptionnel s’explique par l’abondance du corpus (173 621 paires) et la forte couverture préexistante de NLLB sur ces deux langues à fortes ressources. Le faible poids de l’adaptateur (**14 Mo**) illustre l’efficacité de LoRA pour le déploiement contraint.

Un second notebook (`fine_tuning_nllb_fr_en.ipynb`) a été développé pour un adaptateur **bidirectionnel** Français↔Anglais ($r = 16$, 3 époques, 168 460 paires, dépôt : `romaricnadjire/nllb-fr-en-lora`), en attente de quota GPU Kaggle.

2.6.4 Adaptateur LoRA Multilingue (Éwé → Anglais et Éwé → Français)

Un adaptateur LoRA unique couvrant **2 directions simultanées** (Éwé→Anglais et Éwé→Français, source unique = éwé) a été entraîné sur Kaggle (T4×2, batch effectif 16, 3 époques complètes, 10 062 steps, ≈ 2 h 44, loss finale 8,17).

Direction	BLEU	chrF++ (%)
Éwé → Anglais	27,42	46,05
Éwé → Français	6,87	25,09

TABLE 2.17 – Résultats de l’adaptateur multilingue (Éwé→Anglais / Éwé→Français, jeu de test).

Les performances sont quasi-identiques aux adaptateurs directionnels séparés (27,47 et 6,94), ce qui démontre que NLLB peut partager ses connaissances entre directions sans perte de qualité. Cependant, l’entraînement sur 4 directions × 3 époques dépasse systématiquement la **limite de 12 h** par session Kaggle. La stratégie a été réorientée vers des adaptateurs directionnels séparés.

2.7 Synthèse Comparative des Entraînements

Le tableau ci-dessous regroupe l'ensemble des modèles de traduction produits, toutes méthodes et directions confondues.

Direction	Méthode	BLEU	chrF++	Durée	Taille
Éwé→Ang.	Baseline NLLB	13,83	33,09	—	—
Éwé→Ang.	Full FT FP32	22,26	—	≈14 h	3,26 Go
Éwé→Ang.	LoRA ($r=16$)	27,47	46,09	≈2 h	30 Mo
Éwé→Fr.	Baseline NLLB	3,15	18,72	—	—
Éwé→Fr.	Full FT INT8	3,57	—	≈4 h	838 Mo
Éwé→Fr.	Full FT FP16	4,14	—	≈4 h	1,15 Go
Éwé→Fr.	LoRA ($r=16$)	6,94	25,42	≈1 h	30 Mo
Fr.→Ang.	Baseline NLLB	5,67	—	—	—
Fr.→Ang.	LoRA ($r=16$)	61,17	—	≈4 h	14 Mo
Éwé→{Ang.,Fr.}	LoRA multilingue	27,42 / 6,87	46,05 / 25,09	≈3 h	30 Mo

TABLE 2.18 – Comparaison complète de tous les modèles de traduction entraînés.

Conclusions :

- **LoRA surpasse systématiquement le Full FT** pour les paires éwé : +5, 21 pts BLEU (Éwé→Ang.) et +2, 80 pts (Éwé→Fr.) par rapport au meilleur Full FT.
- **Signe d'overfitting du Full FT** : la loss quasi-nulle (0, 0021) sur Éwé→Ang. ne se traduit pas en meilleures performances test que LoRA. Le modèle mémorise le corpus au lieu de généraliser.
- **Efficacité LoRA remarquable** : l'adaptateur 30 Mo obtient BLEU 27,47 contre 22,26 pour le modèle 3,26 Go, en 7 fois moins de temps d'entraînement.
- **Scores éwé-français limités** (BLEU < 7) en raison du faible volume du corpus parallèle éwé-français. L'intégration de tchaye59, kuroio et BibleTTS est la priorité pour améliorer ces résultats.
- **Adaptateur multilingue** : résultats équivalents aux directionnels séparés (BLEU 27,42 vs 27,47), ouvrant la voie à un déploiement plus compact.

2.8 Reconnaissance Vocale Automatique (ASR) en Éwé

La Reconnaissance Vocale Automatique (*Automatic Speech Recognition* — ASR) est une technologie clé du traitement automatique du langage naturel (NLP). Elle vise à convertir un signal acoustique de parole en un texte écrit équivalent. Appliquée à l'Éwé (*ee*), l'implémentation de systèmes ASR soulève des défis scientifiques et techniques uniques, liés à la fois à la nature morphosyntaxique de la langue et à la rareté des ressources numériques disponibles.

2.8.1 Spécificités Linguistiques et Défis Acoustiques de l'Éwé

L'adaptation d'une architecture ASR standard à la langue Éwé nécessite la prise en compte de caractéristiques phonétiques et lexicales strictes :

- **Le système tonal** : L'Éwé est une langue à tons (principalement le ton haut, le ton bas et le ton moyen). La hauteur de la voix (*pitch*) possède une valeur phonologique distinctive : un même phonème prononcé avec deux inflexions différentes change radicalement le sens du mot (par exemple, *tó* signifie « oreille », tandis que *tò* signifie « buffle »). Le modèle acoustique de l'ASR doit donc être capable de capturer et de modéliser les variations fines de fréquence fondamentale (F_0) pour éviter les ambiguïtés lexicales.
- **Phonèmes spécifiques** : L'Éwé intègre des consonnes complexes, notamment les occlusives labio-vélaires /p/ et /gb/, ainsi que des fricatives bilabiales // et //. L'extraction des caractéristiques acoustiques (*features*) doit être suffisamment précise pour discriminer ces sons peu communs dans les langues occidentales majeures.
- **Voyelles nasales et allongements** : La distinction stricte entre voyelles orales et nasales ajoute une

dimension supplémentaire à la variabilité du signal audio que le modèle de deep learning doit apprendre à généraliser.

2.8.2 Architecture d'un Système ASR Appliqué à l'Éwé

Les systèmes modernes reposent majoritairement sur des approches de bout en bout (*End-to-End* — E2E), qui simplifient le pipeline traditionnel en associant directement le signal audio au texte cible.

Le processus de traitement se décline en trois étapes fondamentales :

1. **Prétraitement et Extraction de Caractéristiques** : Le signal audio brut (généralement échantillonné à 16 kHz) est découpé en fenêtres temporelles courtes (de 20 à 30 ms). On y applique une transformée de Fourier pour extraire des représentations fréquentielles adaptées à la perception humaine, telles que les coefficients de prédiction linéaire sur l'échelle Mel (MFCC) ou des *Log-Mel Filterbanks*.
2. **Modélisation Acoustique (Encodeur)** : Des architectures neuronales profondes basées sur des Transformers (comme *Whisper* d'OpenAI ou *Wav2Vec 2.0* de Meta) ou des réseaux de neurones récurrents (LSTM, Conformer) analysent ces représentations pour projeter les vecteurs acoustiques dans un espace latent riche en informations phonétiques.
3. **Modélisation de la Langue et Décodage (Décodeur)** : En s'appuyant sur des critères comme la perte CTC (*Connectionist Temporal Classification*) ou des mécanismes d'attention, le décodeur prédit la séquence de graphèmes ou de sous-mots en Éwé la plus probable, en veillant au respect de la grammaire et de la syntaxe de la langue cible.

2.8.3 Le Problème de la Rareté des Ressources (*Low-Resource Language*)

Le verrou technologique majeur pour l'ASR en Éwé réside dans la constitution des jeux de données :

- **Corpus Audio Transcrit** : Contrairement aux langues dotées de milliers d'heures de données alignées (comme l'Anglais ou le Français), l'Éwé souffre d'un manque crucial de corpus de parole annotés publiquement accessibles.
- **Stratégies de contournement** : Pour pallier cette pénurie, les travaux récents s'orientent vers :
 - Le *Self-Supervised Learning* (SSL) : Utiliser des modèles pré-entraînés sur des volumes massifs d'audio non étiquetés multi-langues, puis effectuer un *fine-tuning* supervisé avec un très faible volume d'audio éwé (par exemple via des initiatives comme Common Voice de Mozilla).
 - L'augmentation de données acoustiques (*SpecAugment*, modification de la vitesse ou du pitch) pour enrichir artificiellement le catalogue d'entraînement.

2.9 Évaluation des performances du système ASR

2.9.1 Présentation des métriques d'évaluation

Pour évaluer la qualité de la reconnaissance automatique de la parole (*Automated Speech Recognition* - ASR), nous utilisons deux indicateurs fondamentaux qui comparent la transcription générée par le modèle avec la référence humaine :

- **WER (Word Error Rate)** : Il mesure le taux d'erreur au niveau des mots en comptabilisant les insertions, suppressions et substitutions.
Interprétation : Plus le score est élevé, plus le modèle éprouve des difficultés à structurer correctement les phrases. Un score faible (proche de 0 %) est l'objectif visé.
- **CER (Character Error Rate)** : Cette métrique mesure le taux d'erreur au niveau des caractères, offrant une analyse plus fine de la précision phonétique et morphologique du modèle.
Interprétation : Tout comme pour le WER, un score élevé traduit une mauvaise reconnaissance des unités minimales de la langue. Une valeur faible est indispensable pour garantir une transcription fidèle, ce qui est crucial pour les langues à ressources limitées comme l'Éwé.

2.9.2 Résultats de la spécialisation du modèle

L'entraînement a permis une spécialisation efficace du modèle NLLB sur notre corpus. Les performances ont été mesurées avant et après la phase d'ajustement fin, mettant en évidence une progression significative.

Phase	WER (%)	CER (%)
Avant Entraînement	100,00	236,73
Après Entraînement (Test)	13,52	2,11

TABLE 2.19 – Comparaison des performances ASR (WER/CER) sur la langue Éwé.

2.9.3 Analyse des performances

L’observation des résultats montre une réduction spectaculaire des taux d’erreur :

- **Sur le plan lexical (WER) :** Le modèle est passé d’une incapacité totale à transcrire le signal audio (WER de 100 %) à un taux d’erreur performant de **13,52 %** sur le jeu de test.
- **Sur le plan morphologique (CER) :** La baisse drastique du CER à **2,11 %** démontre que le modèle a parfaitement assimilé la structure des mots et les spécificités phonétiques de l’Éwé.

Cette convergence confirme que l’ajustement fin a permis de transformer un modèle initialement non adapté en un outil robuste, capable de générer des transcriptions précises. La faiblesse du CER est une preuve tangible de la qualité du modèle à restituer fidèlement les unités minimales de la langue, garantissant ainsi une transcription fiable.

2.9.4 Enrichissement ASR avec WaxalNLP (v2 — en cours)

Afin d’améliorer la robustesse du modèle ASR, une seconde phase d’entraînement (v2) a été initiée, combinant le jeu de données d’origine avec le corpus **WaxalNLP** de Google.

Dataset WaxalNLP

Le dataset `google/WaxalNLP` est un corpus audio multilingue annoté disponible sur Hugging Face. Sa configuration `ewe_asr` contient environ **15 000 clips audio** éwé transcrits. Il apporte une variété acoustique et lexicale complémentaire au jeu d’origine (essentiellement biblique), avec des locuteurs et des thématiques distinctes.

Défis techniques et solutions

Le dataset WaxalNLP complet (toutes langues confondues) dépasse **400 Go**, rendant impossible le téléchargement en bloc sur Kaggle. La solution adoptée est le *mode streaming* (`streaming=True`) : les données audio sont téléchargées à la volée au fur et à mesure de l’entraînement. Seuls les splits de validation et de test (moins de 300 exemples chacun) sont matérialisés en mémoire en amont. Ce mécanisme a nécessité un développement technique spécifique (chaînage d’`IterableDataset`, map paresseux) pour être compatible avec le `Trainer` Hugging Face.

Architecture de la v2

La v2 **recharge** l’adaptateur éwé publié `romaricnadjire/mms-ewe-asr` (WER 13,52 %) et **poursuit** l’entraînement avec un taux d’apprentissage réduit (10^{-4} , contre 10^{-3} au premier run). Un mécanisme de reprise automatique est intégré : en cas d’interruption de la session Kaggle, le dernier checkpoint est retrouvé localement ou téléchargé depuis le dépôt Hub `romaricnadjire/mms-ewe-asr-v2` (stratégie `hub_strategy=checkpoint`, push toutes les 500 steps).

Statut et perspectives

Le notebook Kaggle (v6) est prêt et a été soumis sur la plateforme. L’exécution est en **attente de recharge du quota GPU** (30 h/semaine). Dès que le quota sera disponible, les métriques finales (WER/CER sur le jeu d’origine et sur le nouveau jeu WaxalNLP) seront enregistrées dans `asr_mms_v2_metrics.json` sur le Hub.

Dans un second temps, l’intégration du corpus **BibleTTS** (OpenSLR 129) est envisagée : avec **86,8 heures** de parole éwé studio 48 kHz (locuteur unique, CC BY-SA 4.0), ce corpus est la ressource audio libre la plus volumineuse disponible pour cette langue, et constitue une étape naturelle pour une version ASR v3.

3. Bilan, Limites et Perspectives

3.1 Récapitulatif des Modèles Produits

L'ensemble des travaux menés au cours de ce projet démontre la viabilité de l'adaptation de modèles de langue à grande échelle pour la langue Éwé. Le tableau ci-dessous synthétise l'ensemble des modèles entraînés, leurs métriques et leur état de publication :

Modèle	Direction	Métrique principale	Statut
NLLB Full FT (32-bit)	Éwé → Anglais	BLEU 22,26	Publié
NLLB LoRA	Éwé → Anglais	BLEU 27,47 / chrF++ 46,09	Publié (nllb-ewe-en)
NLLB Full FT (8-bit)	Éwé → Français	BLEU 3,57	Publié
NLLB Full FT (16-bit)	Éwé → Français	BLEU 4,14	Publié
NLLB LoRA	Éwé → Français	BLEU 6,94 / chrF++ 25,42	Publié (nllb-ewe-fr)
NLLB LoRA (Colab, 1 époque)	Français → Anglais	BLEU 61,17	Partiel
NLLB LoRA multilingue	Éwé → {Anglais, Français}	BLEU 27,42 / 6,87 ; chrF++ 46,05 / 25,09	Publié (nllb-ewe-mu)
NLLB LoRA bidirectionnel	Anglais ↔ Français	—	En attente GPU
MMS ASR v1	Parole éwé → Texte	WER 13,52 % / CER 2,11 %	Publié (mms-ewe-as)
MMS ASR v2 (+WaxalNLP)	Parole éwé → Texte	—	En attente GPU

TABLE 3.1 – Synthèse de tous les modèles entraînés dans le cadre du projet.

3.2 Bilan Global

La confrontation entre les différentes approches — du *Full Fine-Tuning* aux méthodes optimisées telles que la quantification et l'adaptation par LoRA — a permis d'établir un compromis stratégique entre performance lexicale et contraintes matérielles.

- **Performance vs Agilité** : La méthode LoRA s'impose comme la solution la plus performante et la plus agile. Avec un score BLEU de 27,47 pour Éwé → Anglais et une empreinte mémoire de 14 Mo (contre plusieurs Go pour le *Full Fine-Tuning*), elle représente le meilleur compromis pour les langues à faibles ressources.
- **Optimisation sous contraintes** : L'étude prouve qu'il est possible de traiter des langues à ressources limitées via des plateformes accessibles (Google Colab, Kaggle) en appliquant des stratégies de gestion mémoire rigoureuses (quantification, streaming de données, précision mixte BF16).
- **Reconnaissance Vocale** : Le modèle ASR MMS fine-tuné atteint un WER de 13,52 % (contre 100 % pour le modèle brut), validant l'efficacité de l'adaptation des modèles multi-langues pré-entraînés aux langues locales peu dotées.

3.3 Limites Actuelles

Malgré les résultats encourageants, plusieurs limites importantes doivent être soulignées :

- **Unidirectionnalité des modèles de traduction** : Les adaptateurs LoRA entraînés couvrent uniquement les directions Éwé → Anglais et Éwé → Français. Les directions inverses (Anglais → Éwé, Français → Éwé) n'ont pas encore été entraînées, limitant les cas d'usage du système à la traduction depuis l'éwé uniquement.
- **Contraintes de quota GPU** : La limite de 12 heures par session sur Kaggle a rendu impossible l'entraînement d'un adaptateur multilingue unique (4 directions × 3 époques), conduisant à l'abandon de cette approche.
- **Modèles en attente** : Le modèle NLLB bidirectionnel Français ↔ Anglais et la version v2 du modèle ASR (avec WaxalNLP) sont techniquement prêts mais en attente de quota GPU.
- **Biais du corpus** : Une part significative des données éwé provient de textes bibliques (OPUS), ce qui peut

induire un biais de domaine (vocabulaire solennel, structures archaïques) peu adapté aux conversations quotidiennes.

3.4 Perspectives d'Amélioration

Les travaux réalisés ouvrent plusieurs pistes concrètes pour les développements futurs :

- **Entraînement bidirectionnel complet** : Ré-entraîner les modèles de traduction en intégrant les directions inverses (Anglais → Éwé, Français → Éwé) avec des données parallèles augmentées. Cela permettrait de construire un système de traduction pleinement bidirectionnel pour les trois langues du projet.
- **Finalisation des modèles en cours** : Compléter l'entraînement du modèle ASR v2 (WaxalNLP + données d'origine) et du modèle NLLB Français ↔ Anglais bidirectionnel dès le renouvellement du quota GPU.
- **Compléter l'ASR v2 avec WaxalNLP** : Le notebook est prêt et soumis (Kaggle v6). Dès le renouvellement du quota GPU, l'entraînement combinant le jeu d'origine et WaxalNLP (15 000 clips) sera exécuté pour mesurer le gain de WER/CER par rapport au modèle v1 (13,52 %).
- **ASR v3 avec BibleTTS (OpenSLR 129)** : Le corpus BibleTTS fournit **86,8 heures** d'audio éwé studio aligné (CC BY-SA 4.0, 24 957 énoncés, 48 kHz). Son intégration dans une prochaine version du modèle ASR permettrait de multiplier par ≈ 6 le volume de données d'entraînement, au prix d'un biais de domaine biblique similaire au corpus textuel OPUS.
- **Enrichissement du corpus de traduction** : Intégrer les données Kaggle tchaye59 (7,2 Mo, sources diversifiées : littéraire, DUDH, religieux) et, après vérification des doublons, kuroio (5,6 Mo) pour enrichir le corpus éwé-anglais au-delà du seul OPUS biblique.
- **Entraînement bidirectionnel complet** : Ré-entraîner les adaptateurs LoRA en intégrant les directions inverses (Anglais → Éwé, Français → Éwé) avec les corpus enrichis. Les données bilingues tchaye59 et kuroio seront particulièrement utiles pour ce sens moins documenté.
- **Déploiement applicatif** : Intégrer les modèles dans une interface web ou mobile permettant une traduction et une interaction vocale en éwé en temps réel, au service des populations locales.
- **Évaluation humaine** : Compléter les évaluations automatiques (BLEU, chrF++, WER) par des évaluations impliquant des locuteurs natifs éwé pour affiner la qualité perçue des traductions et de la reconnaissance vocale.

"L'efficacité d'un modèle ASR ou de traduction pour une langue à faibles ressources ne réside pas uniquement dans sa puissance brute, mais dans la précision de son ajustement et l'optimisation de son empreinte technique pour le déploiement réel."

4. Ressources Numériques et Liens Utiles

[← Cliquez ici pour retourner au texte du rapport](#)

Plateforme	Description	Lien d'Accès
Kaggle	Hébergement de datasets et notebooks.	https://www.kaggle.com
OPUS	Corpus de traduction ouverte (Bible éwé-anglais).	https://opus.nlpl.eu
Masakhane — Lafand-MT	Corpus parallèle Français-Éwé (journalistique).	https://github.com/masakhane-io/lafand-mt/tree/main/data/doc_level_tsv/fra-ewe
Kaggle — tchaye59	Paires bilingues Éwé-Anglais diversifiées (7,2 Mo).	https://www.kaggle.com/datasets/tchaye59/eweenglish-bilingual-pairs
Kaggle — kuroio	Fichier CSV Éwé-Anglais complémentaire (5,6 Mo).	https://www.kaggle.com/datasets/kuroio/ewe-english-train-csv
WaxalNLP (Google)	Corpus audio multilingue éwé — ≈15k clips (HF).	https://huggingface.co/datasets/google/WaxalNLP
BibleTTS — OpenSLR 129	86,8h audio éwé studio aligné, CC BY-SA 4.0 (18 Go).	https://www.openslr.org/129/
peterlin.pl	Site éducatif Éwé (textes bilingues culturels, référence).	http://www.peterlin.pl/ewe/

TABLE 1 – Liste des liens et ressources de données utilisées.